




YOLO: YOU_ONLY_LOOK_ONCE

EL FUTURO DE LA DETECCIÓN DE OBJETOS EN TIEMPO REAL.

Dianne Parroquin Diaz

CLASIFICACIÓN VS. LOCALIZACIÓN




► **Clasificación:** Identifica qué objeto está presente en una imagen (ej. "es un gato").

Localización: Identifica dónde está el objeto dentro de la imagen mediante un cuadro delimitador.

Ejemplo: Una imagen con un gato clasificada como "gato" con un recuadro marcando su ubicación exacta.

¿QUÉ ES YOLO?



- ▶ YOLO significa "You Only Look Once". Es un algoritmo de detección de objetos en imágenes y videos en tiempo real. Funciona procesando toda la imagen en una sola pasada para identificar múltiples objetos simultáneamente, lo que lo hace extremadamente rápido y eficiente.


EVOLUCIÓN DE YOLO

2015: LANZAMIENTO INICIAL POR JOSEPH REDMON


YOLOV2-V3: MAYOR PRECISIÓN Y VELOCIDAD

YOLOV4-V5: OPTIMIZACIÓN Y EFICIENCIA

YOLOV6-V8+: ARQUITECTURAS AVANZADAS




COMPARACIÓN CON OTROS ALGORITMOS




R-CNN (Dos Etapas)
Genera propuestas de regiones primero, luego clasifica cada una. Alta precisión pero lento.



Faster R-CNN
Mejora R-CNN con red de propuestas integrada. Más rápido pero aún requiere dos etapas de procesamiento.




YOLO (Una Etapa)
Procesa imagen completa en una sola pasada. Detección en tiempo real con alta velocidad.




Compromisos
YOLO sacrifica precisión en objetos pequeños por velocidad. Ideal para aplicaciones en tiempo real.

¿CÓMO FUNCIONA YOLO?




- ▶ **YOLO divide la imagen en una cuadrícula de celdas. Cada celda predice cajas delimitadoras con probabilidades de clase para detectar objetos. Todo el procesamiento ocurre en una sola pasada, permitiendo detección en tiempo real con alta velocidad y eficiencia.**

ARQUITECTURA Y EXTRACCIÓN DE CARACTERÍSTICAS




- ▶ **YOLO utiliza redes neuronales convolucionales (CNN) para extraer características relevantes de la imagen. La red procesa la imagen completa en una sola pasada, prediciendo múltiples cajas delimitadoras y clases simultáneamente. La función de pérdida combina errores de localización y clasificación para optimizar el modelo.**


¿CÓMO FUNCIONA YOLO?



Divide la imagen en una cuadrícula de celdas.




Cada celda predice cajas delimitadoras con probabilidades de clase para detectar objetos.



Mediante el algoritmo de Non-maximum Suppression obtenemos una única bounding box por objeto.

Todo el procesamiento ocurre en una sola pasada, permitiendo detección en tiempo real con alta velocidad y eficiencia.

¿CÓMO FUNCIONA YOLO? – PREDICCIÓN Y FILTRADO



- Cada celda emite predicciones con coordenadas (x, y, ancho, alto) y probabilidades de clase. Se aplica **Non-Maximum Suppression (NMS)** para eliminar cajas solapadas y conservar solo las más confiables. El resultado final es un conjunto de objetos detectados con su ubicación precisa y clasificación.

ELEMENTOS DE CODIFICACIÓN

“SCORE DE CONFIANZA”

Para decidir si una caja es válida, YOLO calcula un 'Score de Confianza'


Formula para calcular el Score de Confianza

$$\text{Score de Confianza} = P(\text{Objeto}) \times \text{IoU}_{\text{pred}}^{\text{truth}} \times P(\text{Clase} \mid \text{Objeto})$$



ELEMENTOS DE CODIFICACIÓN DEL “BOUNDING BOX”

Vector de Salida Y



ELEMENTOS DE CODIFICACIÓN DEL “BOUNDING BOX”

Codificación de la clase de objetos



$$Y = \begin{bmatrix} \text{Pr} \\ \text{Bx} \\ \text{By} \\ \text{Bw} \\ \text{Bh} \\ \text{C1} \\ \text{C2} \end{bmatrix} \rightarrow \begin{bmatrix} 1 \\ 0.4 \\ 0.5 \\ 0.5 \\ 0.7 \\ 1 \\ 0 \end{bmatrix}$$

Supongamos que
queremos detectar
2 tipos de objetos:
“Silla” y “mesa”

ELEMENTOS DE CODIFICACIÓN DEL “BOUNDING BOX”

¿y si no hay objetos que detectar?



$$Y = \begin{bmatrix} \text{Pr} \\ \text{Bx} \\ \text{By} \\ \text{Bw} \\ \text{Bh} \\ \text{C1} \\ \text{C2} \end{bmatrix}$$

$$Y = \begin{bmatrix} 0 \\ - \\ - \\ - \\ - \\ - \\ - \end{bmatrix}$$

Cuando $\text{Pr} = 0$, sabemos que la imagen no contiene ningún valor de interés, por lo cual no tiene relevancia para las predicciones.

IoU-Intersección sobre la union (INTERSECTION OVER UNION)



Bounding Box Ideal



Bounding Box Predicho




¿Que tanto se parece la predicción
al Bounding Box ideal?

IoU-Intersección sobre la union (INTERSECTION OVER UNION)


¿Cómo cuantificar ese grado de similitud?



Intersección




Union



$$\text{IoU} = \frac{\text{Intersección}}{\text{Union}}$$


IoU-Intersección sobre la union (INTERSECTION OVER UNION)

En el peor de los casos donde la predicción no coincide con el ideal el IoU es 0



Intersección = 0

Union = Elementos
por separado



$$\text{IoU} = \frac{\text{Intersección}}{\text{Union}}$$


$$\text{IoU} = 0$$

IoU-Intersección sobre la union (INTERSECTION OVER UNION)


En el mejor de los casos la predicción es perfecta



Intersección



Union



$$\text{IoU} = \frac{\text{Intersección}}{\text{Union}}$$

$$\underline{\text{IoU} = 1}$$

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)



Predicción ideal




Predicción en practica

El la practica el modelo puede detectar más de un bounding box en la imagen, por lo cual es necesario eliminar aquellos que sobren para dejar solo uno por objeto.

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA




1. Eliminar los “bounding boxes” con $Pr < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.

$$Y = \begin{bmatrix} Pr \\ Bx \\ By \\ Bw \\ Bh \\ C1 \\ C2 \end{bmatrix}$$

→ Probabilidad de que haya objetos en la imagen

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $Pr < \text{umbral}(0.6)$.

2. Tomar el “bounding box” con el Pr más alto como predicción.

3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.

4. Descartar los bounding boxes con $IoU > \text{Umbral}(0.5)$.


5. Repetir (2) a (4) con los “bounding boxes” que queden.

$$Y = \begin{bmatrix} Pr \\ Bx \\ By \\ Bw \\ Bh \\ C1 \\ C2 \end{bmatrix}$$

→ Probabilidad de que haya objetos en la imagen

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)


CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $Pr < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $Pr < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.


$\text{IoU} = 0$

$\text{IoU} = 0.2$

$\text{IoU} = 0.8$

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $\text{Pr} < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.


$$\text{IoU} = 0.8$$

$$\text{IoU} = 0$$

$$\text{IoU} = 0.2$$

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)


CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $Pr < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



$\text{IoU} = 0.9$

1. Eliminar los “bounding boxes” con $\text{Pr} < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)


CASO I. MÚLTIPLES OBJETOS DE LA MISMA CATEGORÍA



1. Eliminar los “bounding boxes” con $Pr < \text{umbral}$ (0.6).
2. Tomar el “bounding box” con el Pr más alto como predicción.
3. Calcular el IoU entre el “bounding box” tomado en (2) y los “bounding boxes” restantes.
4. Descartar los bounding boxes con $\text{IoU} > \text{Umbral}$ (0.5).
5. Repetir (2) a (4) con los “bounding boxes” que queden.

SUPRESIÓN DE NO-MÁXIMOS (NON-MAX SUPPRESSION)

CASO II. MÚLTIPLES OBJETOS Y MÚLTIPLES CATEGORÍAS



En caso de que existan multiples objetos se realiza el mismo procedimiento pero para cada categoría de objeto

¿CÓMO DETECTAR OBJETOS CUANDO SE SUPERPONEN?



Cada vector corresponde
a un solo objeto

$Y =$

$\begin{bmatrix} \text{Pr} \\ \text{Bx} \\ \text{By} \\ \text{Bw} \\ \text{Bh} \\ \text{C1} \\ \text{C2} \end{bmatrix}$

$Y =$

$\begin{bmatrix} \text{Pr} \\ \text{Bx} \\ \text{By} \\ \text{Bw} \\ \text{Bh} \\ \text{C1} \\ \text{C2} \end{bmatrix}$

Por ello se
concatenan los
vectores

$Y =$

$\begin{bmatrix} 1 \\ 0.4 \\ 0.4 \\ 0.6 \\ 0.8 \\ 1 \\ 0 \\ 1 \\ 0.3 \\ 0.6 \\ 0.5 \\ 0.8 \\ 0 \\ 1 \end{bmatrix}$

CUANDO SOLO HAY UN TIPO DE OBJETO



Cada vector corresponde
a un solo objeto

$$Y = \begin{bmatrix} Pr \\ Bx \\ By \\ Bw \\ Bh \\ C1 \\ C2 \end{bmatrix}$$


$$Y = \begin{bmatrix} Pr \\ Bx \\ By \\ Bw \\ Bh \\ C1 \\ C2 \end{bmatrix}$$

Y =

$$\begin{bmatrix} 0 \\ - \\ - \\ - \\ - \\ - \\ - \\ 1 \\ 0.3 \\ 0.6 \\ 0.5 \\ 0.8 \\ 0 \\ 1 \end{bmatrix}$$

¿CÓMO SE ENTRENA LA RED NEURONAL YOLO?


ENTRENAMIENTO:



VECTOR DE
(5+N) X 2 ELEMENTOS

CATEGORIAS


- [1,0,0] = "SILLA"
- [0,1,0] = "MESA"
- [0,0,1] = "SOFÁ"




SUPONIENDO QUE SE PUEDEN SUPERPONER
MÁXIMO DOS OBJETOS

ENTRENAMIENTO:


Suponiendo que queremos entrenar al algoritmo con la siguiente imagen.



Observamos que hay dos objetos
sobrepuestos




Se genera una cuadrícula de 4x4
(Puede ser cualquier valor)



La celda la codificamos únicamente si
contiene el centro del bounding box, y las
celdas demás no nos interesan


ENTRENAMIENTO:

Suponiendo que queremos entrenar al algoritmo con la siguiente imagen.




LA IDEA ES QUE ESTO SE REALIZA PARA
UN GRAN VOLUMEN DE IMAGENES

ENTRENAMIENTO YOLO




PREDICCIÓN YOLO


PREDICCIÓN



RED CONVOLUCIONAL



PREDICCIÓN



RENDIMIENTO Y APLICABILIDAD



Tiempo Real
YOLO destaca en detección en tiempo real, procesando hasta 45+ FPS en hardware estándar.



Precisión General
YOLO ofrece buena precisión en la mayoría de escenarios, siendo competitivo con métodos más complejos.



Balance Óptimo
YOLO equilibra velocidad y precisión, ideal para aplicaciones que requieren respuesta inmediata.



Casos Específicos
Otros algoritmos superan a YOLO en objetos pequeños o escenas muy complejas.

VENTAJAS DE YOLO



Rapidez

Detección de objetos en tiempo real, procesando hasta 45 fotogramas por segundo en su versión estándar.



Eficiencia

Procesamiento de la imagen completa en una sola pasada, optimizando recursos computacionales.



Precisión

Alta exactitud en la detección múltiple de objetos, con mínimos falsos positivos.



Flexibilidad

Adaptable a distintas aplicaciones: desde vigilancia hasta vehículos autónomos.

APLICACIONES PROFESIONALES DE YOLO



Vehículos Autónomos
Detección rápida de peatones, vehículos, señales de tráfico y obstáculos para navegación segura.



Vigilancia y Seguridad
Monitoreo en tiempo real de espacios públicos y privados, detección de intrusos y comportamientos sospechosos.




Industria y Control de Calidad
Inspección automatizada de productos, detección de defectos y optimización de procesos de manufactura.



Análisis Deportivo
Seguimiento de jugadores y balón, análisis táctico automatizado y generación de estadísticas en tiempo real.

AVANCES RECIENTES EN YOLO



- ▶ Las versiones más recientes de YOLO incorporan arquitecturas mejoradas como CSPNet y transformers para mayor precisión. La integración con técnicas de aprendizaje profundo avanzado y optimización de hiperparámetros ha permitido modelos más eficientes. YOLOv8 y variantes como YOLO-NAS representan el estado del arte actual.

RETOS Y LIMITACIONES

DETECCIÓN DE OBJETOS PEQUEÑOS O MUY PRÓXIMOS


SENSIBILIDAD A CONDICIONES DE ILUMINACIÓN Y ÁNGULOS

NECESIDAD DE GRANDES CONJUNTOS DE DATOS PARA ENTRENAMIENTO

LIMITACIONES EN ESCENAS MUY COMPLEJAS

DEMOSTRACIÓN YOLO

A continuación, observaremos YOLO en acción mediante una demostración práctica de detección de objetos. Veremos cómo el algoritmo procesa imágenes y videos, identificando múltiples objetos simultáneamente con alta velocidad y precisión.

A screenshot of the YOLO Object Detection web interface. It features a dark blue header with the text 'YOLO Object Detection' and a magnifying glass icon. Below the header, there is a light blue box containing the text 'Upload an image or video to detect objects using state-of-the-art YOLO models'. The background of the interface is dark blue with a subtle pattern of light blue dots.


YOLO Object Detection

Upload an image or video to detect objects using state-of-the-art YOLO models

RESUMEN Y CONCLUSIÓN

- ▶ YOLO COMBINA CLASIFICACIÓN Y LOCALIZACIÓN EN UN SOLO PASO
- ▶ LOGRA DETECCIÓN RÁPIDA Y EFICIENTE DE OBJETOS
- ▶ EQUILIBRA VELOCIDAD Y PRECISIÓN PARA APLICACIONES EN TIEMPO REAL
- ▶ CONTINÚA EVOLUCIONANDO CON MEJORAS TÉCNICAS CONSTANTES
- ▶ AMPLIACIÓN DE APLICACIONES EN MÚLTIPLES INDUSTRIAS

REFERENCIAS




A COMPREHENSIVE REVIEW OF YOLO ARCHITECTURES IN COMPUTER VISION: FROM YOLOV1 TO YOLOV8 AND YOLO-NAS

Terven, J., Córdova-Esparza, D.-M., & Romero-González, J.-A. (2023). A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS. Machine Learning and Knowledge Extraction, 5(4), 1680–1716. <https://doi.org/10.3390/make5040083>



YOLOV10: REAL-TIME END-TO-END OBJECT DETECTION

Wang, A., Chen, Hui, Liu, L., Chen, K., Lin, Z., Han, J., & Ding, G. (2024). YOLOv10: Real-time end-to-end object detection (arXiv Preprint arXiv:2405.14458). arXiv. <https://doi.org/10.48550/arXiv.2405.14458>



MUCHAS

GRACIAS

Dianne Parroquin Diaz